

# Day08回顾

## scrapy框架

### ■ 五大组件+工作流程+常用命令

```
1  【1】五大组件
2      1.1) 引擎 (Engine)
3      1.2) 爬虫程序 (Spider)
4      1.3) 调度器 (Scheduler)
5      1.4) 下载器 (Downloader)
6      1.5) 管道文件 (Pipeline)
7      1.6) 下载器中间件 (Downloader Middlewares)
8      1.7) 蜘蛛中间件 (Spider Middlewares)
9
10 【2】工作流程
11     2.1) Engine向Spider索要URL,交给Scheduler入队列
12     2.2) Scheduler处理后出队列,通过Downloader Middlewares交给Downloader去下载
13     2.3) Downloader得到响应后,通过Spider Middlewares交给Spider
14     2.4) Spider数据提取:
15         a) 数据交给Pipeline处理
16         b) 需要跟进URL,继续交给Scheduler入队列,依次循环
17
18 【3】常用命令
19     3.1) scrapy startproject 项目名
20     3.2) scrapy genspider 爬虫名 域名
21     3.3) scrapy crawl 爬虫名
```

## 完成scrapy项目完整流程

### ■ 完整流程

```
1  【1】 scrapy startproject Tencent
2  【2】 cd Tencent
3  【3】 scrapy genspider tencent tencent.com
4  【4】 items.py(定义爬取数据结构)
5      import scrapy
6      class TencentItem(scrapy.Item):
7          name = scrapy.Field()
8          address = scrapy.Field()
9
10 【5】 tencent.py (写爬虫文件)
11     import scrapy
```

```

12     from ..items import TencentItem
13     class TencentSpider(scrapy.Spider):
14         name = 'tencent'
15         allowed_domains = ['tencent.com']
16         start_urls = []
17         def parse(self, response):
18             item = TencentItem()
19             item['name'] = xxxx
20             yield item
21
22 【6】 pipelines.py(数据处理)
23     class TencentPipeline(object):
24         def process_item(self, item, spider):
25             return item
26
27 【7】 settings.py(全局配置)
28     LOG_LEVEL = '' # DEBUG < INFO < WARNING < ERROR < CRITICAL
29     LOG_FILE = ''
30     FEED_EXPORT_ENCODING = ''
31
32 【8】 run.py
33     from scrapy import cmdline
34     cmdline.execute('scrapy crawl tencent'.split())

```

## 我们必须记住

### ■ 熟练记住

```

1 【1】 响应对象response属性及方法
2     1.1) response.text : 获取响应内容 - 字符串
3     1.2) response.body : 获取bytes数据类型
4     1.3) response.xpath('')
5     1.4) response.xpath('').extract() : 提取文本内容,将列表中所有元素序列化为Unicode字符串
6     1.5) response.xpath('').extract_first() : 序列化提取列表中第1个文本内容
7     1.6) response.xpath('').get() : 提取列表中第1个文本内容(等同于extract_first())
8
9 【2】 settings.py中常用变量
10    2.1) 设置日志级别
11        LOG_LEVEL = ''
12    2.2) 保存到日志文件(不在终端输出)
13        LOG_FILE = 'xxx.log'
14    2.3) 设置数据导出编码(主要针对于json文件)
15        FEED_EXPORT_ENCODING = 'utf-8'
16    2.4) 设置User-Agent
17        USER_AGENT = ''
18    2.5) 设置最大并发数(默认为16)
19        CONCURRENT_REQUESTS = 32
20    2.6) 下载延迟时间(每隔多长时间请求一个网页)
21        DOWNLOAD_DELAY = 0.5
22    2.7) 请求头
23        DEFAULT_REQUEST_HEADERS = {'Cookie' : 'xxx'}
24    2.8) 添加项目管道
25        ITEM_PIPELINES = {'目录名.pipelines.类名' : 优先级}

```

```

26     2.9) cookie(默认禁用,取消注释-True|False都为开启)
27         COOKIES_ENABLED = False
28     2.10) 非结构化数据存储路径
29         IMAGES_STORE = '/home/tarena/images/'
30         FILES_STORE = '/home/tarena/files/'
31     2.11) 添加下载器中间件
32         DOWNLOADER_MIDDLEWARES = {'项目目录名.middlewares.类名' : 200}
33
34     【3】 日志级别
35         DEBUG < INFO < WARNING < ERROR < CRITICAL

```

## 爬虫项目启动方式

### ■ 启动方式

```

1     【1】 方式一:基于start_urls
2         1.1) 从爬虫文件(spider)的start_urls变量中遍历URL地址交给调度器入队列,
3         1.2) 把下载器返回的响应对象(response) 交给爬虫文件的parse(self,response)函数处理
4
5     【2】 方式二
6         重写start_requests()方法,从此方法中获取URL,交给指定的callback解析函数处理
7         2.1) 去掉start_urls变量
8         2.2) def start_requests(self):
9             # 生成要爬取的URL地址,利用scrapy.Request()方法交给调度器

```

## 数据持久化存储

### ■ MySQL-MongoDB-Json-csv

```

1     *****存入MySQL、MongoDB*****
2
3     【1】 在setting.py中定义相关变量
4     【2】 pipelines.py中新建管道类,并导入settings模块
5         def open_spider(self,spider):
6             # 爬虫开始执行1次,用于数据库连接
7
8         def process_item(self,item,spider):
9             # 用于处理抓取的item数据
10            return item
11
12        def close_spider(self,spider):
13            # 爬虫结束时执行1次,用于断开数据库连接
14
15    【3】 settings.py中添加此管道
16        ITEM_PIPELINES = {'':200}
17
18    【注意】 process_item() 函数中一定要 return item
19
20    *****存入JSON、CSV文件*****
21    scrapy crawl maoyan -o maoyan.csv

```

```
22 scrapy crawl maoyan -o maoyan.json
23 【注意】
24 存入json文件时候需要添加变量(settings.py) : FEED_EXPORT_ENCODING = 'utf-8'
```

## 多级页面抓取之爬虫文件

### ■ 多级页面攻略

```
1  【场景1】只抓取一级页面的情况
2  """
3  一级页面: 名称(name)、爱好(likes)
4  """
5  import scrapy
6  from ..items import OneItem
7  class OneSpider(scrapy.Spider):
8      name = 'One'
9      allowed_domains = ['www.one.com']
10     start_urls = ['http://www.one.com']
11     def parse(self, response):
12         dd_list = response.xpath('//dd')
13         for dd in dd_list:
14             # 创建item对象
15             item = OneItem()
16             item['name'] = dd.xpath('./text()').get()
17             item['likes'] = dd.xpath('./text()').get()
18
19         yield item
20
21
22  【场景2】二级页面数据抓取
23  """
24  一级页面: 名称(name)、详情页链接(url)-需要继续跟进
25  二级页面: 详情页内容(content)
26  """
27  import scrapy
28  from ..items import TwoItem
29
30  class TwoSpider(scrapy.Spider):
31      name = 'two'
32      allowed_domains = ['www.two.com']
33      start_urls = ['http://www.two.com/']
34      def parse(self, response):
35          """一级页面解析函数,提取 name 和 url(详情页链接,需要继续请求)"""
36          dd_list = response.xpath('//dd')
37          for dd in dd_list:
38              # 有继续交给调度器入队列的请求,就要创建item对象
39              item = TwoItem()
40              item['name'] = dd.xpath('./text()').get()
41              item['url'] = dd.xpath('./@href').get()
42
43              yield scrapy.Request(
44                  url=item['url'], meta={'item': item}, callback=self.detail_page)
45
```

```

46     def detail_page(self, response):
47         item = response.meta['item']
48         item['content'] = response.xpath('//text()').get()
49
50         yield item
51
52
53 【场景3】三级页面抓取
54 """
55 一级页面：名称(one_name)、详情页链接(one_url)-需要继续跟进
56 二级页面：名称(two_name)、下载页链接(two_url)-需要继续跟进
57 三级页面：具体所需内容(content)
58 """
59 import scrapy
60 from ..items import ThreeItem
61
62 class ThreeSpider(scrapy.Spider):
63     name = 'three'
64     allowed_domains = ['www.three.com']
65     start_urls = ['http://www.three.com/']
66
67     def parse(self, response):
68         """一级页面解析函数 - one_name、one_url"""
69         dd_list = response.xpath('//dd')
70         for dd in dd_list:
71             # 有继续发往调度器的请求,创建item对象的时刻到啦!!!
72             item = ThreeItem()
73             item['one_name'] = dd.xpath('./text()').get()
74             item['one_url'] = dd.xpath('./@href').get()
75             yield scrapy.Request(
76                 url=item['one_url'], meta={'meta_1': item}, callback=self.parse_two)
77
78     def parse_two(self, response):
79         """二级页面解析函数: two_name、two_url"""
80         meta1_item = response.meta['meta_1']
81         li_list = response.xpath('//li')
82         for li in li_list:
83             # 有继续交给调度器入队列的请求啦, 所以创建item对象的时刻来临了!!!
84             item = ThreeItem()
85             item['two_name'] = li.xpath('./text()').get()
86             item['two_url'] = li.xpath('./@href').get()
87             item['one_name'] = meta1_item['one_name']
88             item['one_url'] = meta1_item['one_url']
89             # 交给调度器入队列
90             yield scrapy.Request(
91                 url=item['two_url'], meta={'meta_2': item}, callback=self.detail_page)
92
93     def detail_page(self, response):
94         """三级页面解析: 具体内容content"""
95         item = response.meta['meta_2']
96         # 太好了! 提具体内容了,没有继续交给调度器的请求了! 所以,我不再去创建item对象啦
97         item['content'] = response.xpath('//text()').get()
98
99         # 交给管道文件处理
100        yield item

```

# Day09笔记

## 文件管道使用方法

```
1 【1】爬虫文件：将文件链接yield到管道
2 【2】管道文件：
3     from scrapy.pipelines.files import FilesPipeline
4     class XxxPipeline(FilesPipeline):
5         def get_media_requests(self,xxx):
6             把链接交给调度器入队列
7
8         def file_path(self,xxx):
9             此处生成文件名
10            return filename
11
12 【3】 settings.py中：
13     FILES_STORE = '路径'
```

## 图片管道使用方法

```
1 【1】爬虫文件：将图片链接yield到管道
2 【2】管道文件：
3     from scrapy.pipelines.images import ImagesPipeline
4     class XxxPipeline(ImagesPipeline):
5         def get_media_requests(self,xxx):
6             pass
7
8         def file_path(self,xxx):
9             处理文件名
10            return filename
11
12 【3】 settings.py中：
13     IMAGES_STORE = '路径'
```

## 第一PPT模板下载 - 文件管道

### ■ 项目概述

```
1 【1】 URL地址
2     1.1) http://www.1ppt.com/xiazai/
3         抓取所有栏目分类的所有页的PPT文件
4
5 【2】 文件保存路径
6     /home/tarena/ppt/xxx/xxx.rar
7     /home/tarena/ppt/工作总结PPT/清爽绿色多边形背景工作总结汇报PPT模板.zip
8
```

```

9  【3】思路
10  3.1) 主页提取数据：所有分类名称、所有分类链接
11      基准xpath: //div[@class="col_nav clearfix"]/ul/li
12      分类名称: ./a/text()
13      分类链接: ./a/@href
14  3.2) 获取每个分类下的PPT总页数
15      获取'末页'节点,想办法提取 : //ul[@class="pages"]/li[last()]/a/@href
16      total = int(last_page_a.split('.')[0].split('_')[-1])
17  3.3) 获取一页中所有PPT的名称、链接
18      基准xpath: //ul[@class="tplist"]/li
19      PPT名称: ./h2/a/text()
20      PPT链接: ./a/@href
21  3.4) 获取具体ppt下载链接
22      下载链接: //ul[@class="downurllist"]/li/a/@href

```

## 项目实施

### ■ 1 - 创建项目和爬虫文件

```

1  scrapy startproject Ppt
2  cd Ppt
3  scrapy genspider ppt www.1ppt.com

```

### ■ 2 - 定义抓取的数据结构

```

1  import scrapy
2
3  class PptItem(scrapy.Item):
4      # pipelines.py中所需数据: 大分类名称、具体PPT文件名、PPT下载链接
5      parent_name = scrapy.Field()
6      ppt_name = scrapy.Field()
7      download_url = scrapy.Field()

```

### ■ 3 - 爬虫文件提取数据

```

1  # -*- coding: utf-8 -*-
2  import scrapy
3  from ..items import PptItem
4
5  class PptSpider(scrapy.Spider):
6      name = 'ppt'
7      allowed_domains = ['www.1ppt.com']
8      start_urls = ['http://www.1ppt.com/xiazai/']
9
10     def parse(self, response):
11         """一级页面解析函数: 提取大分类的名称、链接"""
12         # li_list : [<Selector1栏目分类>, <Selector2>, ..., <Selector30>]
13         li_list = response.xpath('//div[@class="col_nav clearfix"]/ul/li')
14         for li in li_list[1:]:
15             item = PptItem()
16             # 名称 + 链接

```

```

17         item['parent_name'] = li.xpath('./a/text()').get()
18         partent_url = 'http://www.1ppt.com' + li.xpath('./a/@href').get()
19         # 把大分类的链接交给调度器入队列
20         yield scrapy.Request(url=partent_url, meta={'meta1':item,
'parent_url':partent_url}, callback=self.get_total_page)
21
22     def get_total_page(self, response):
23         """提取内容：所有大分类的总页数,并拼接每页的URL地址,交给调度器入队列"""
24         meta1 = response.meta['meta1']
25         parent_url = response.meta['parent_url']
26         # 因为有的类别下PPT总页数只有1页,所以此处会抛出异常
27         # 当只有1页时会抛出异常
28         try:
29             # last_page_href : ppt_zongjie_20.html
30             last_page_href =
response.xpath('//ul[@class="pages"]/li[last()]/a/@href').get()
31             total_page = int(last_page_href.split('.')[0].split('_')[-1])
32             # 拼接多页的URL地址
33             for page in range(1, total_page+1):
34                 # http://www.1ppt.com/xiazai/zongjie/ + ppt_zongjie_2.html
35                 # ['ppt_zongjie_2', 'html']
36                 # ['ppt', 'zongjie', '2']
37                 # ['ppt', 'zongjie']
38                 # 'ppt_zongjie' + '_' + str(page) + '.html'
39                 page_url = parent_url + '_'.join(last_page_href.split('.')[0].split('_')
[:-1]) + '_' + str(page) + '.html'
40                 yield scrapy.Request(url=page_url, meta={'meta2':meta1},
callback=self.get_ppt_info)
41             except Exception as e:
42                 # 捕捉到异常后,说明这个类别下只有1页PPT,把这个分类的主页URL地址交给调度器入队列
43                 # 此请求在一级页面中已经交给调度器入队列,所以此处会直接对请求去重,不会进入调度器
44                 # 调度器生成指纹的规则: url1、method、请求体 进行sha1()加密生成指纹
45                 # 解决方案: dont_filter 参数
46                 yield scrapy.Request(url=parent_url, meta={'meta2':meta1},
callback=self.get_ppt_info, dont_filter=True)
47
48     def get_ppt_info(self, response):
49         """提取内容: ppt名字、ppt详情页链接"""
50         meta2 = response.meta['meta2']
51         li_list = response.xpath('//ul[@class="tplist"]/li')
52         for li in li_list:
53             # ppt_name 需要交给管道处理
54             item = PptItem()
55             item['ppt_name'] = li.xpath('./h2/a/text()').get()
56             item['parent_name'] = meta2['parent_name']
57             son_url = 'http://www.1ppt.com' + li.xpath('./a/@href').get()
58
59             yield scrapy.Request(url=son_url, meta={'item':item},
callback=self.get_download_url)
60
61     def get_download_url(self, response):
62         """提取内容: PPT下载链接"""
63         item = response.meta['item']
64         item['ppt_download'] =
response.xpath('//ul[@class="downurllist"]/li/a/@href').get()
65
66         # 至此,1条完整数据提取完成

```



#### ■ 4 - 管道文件

```

1 from scrapy.pipelines.files import FilesPipeline
2 import scrapy
3 import os
4
5 class PptPipeline(FilesPipeline):
6     # 重写get_media_requests()方法
7     def get_media_requests(self, item, info):
8         """把一堆的下载链接交给了调度器入队列"""
9         # 把meta包装到请求对象中 request
10        yield scrapy.Request(url=item['ppt_download'], meta={'item':item})
11
12    # 重写file_path方法,保存到对应路径
13    def file_path(self, request, response=None, info=None):
14        # FILES_STORE: /home/tarena/ppt/
15        # filename: 工作总结PPT/小清新.zip      item['parent_name']/item['ppt_name'].zip
16        # scrapy.Request()中所有的参数,都可以作为请求对象 request 的属性
17        item = request.meta['item']
18        filename = '{}/{}/{}'.format(
19            item['parent_name'],
20            item['ppt_name'],
21            os.path.splitext(request.url)[1]
22        )
23
24        return filename

```

#### ■ 5 - 全局配置

```

1 ROBOTSTXT_OBEY = False
2 DOWNLOAD_DELAY = 1
3 DEFAULT_REQUEST_HEADERS = {
4     'Accept': 'text/html,application/xhtml+xml,application/xml;q=0.9,*/*;q=0.8',
5     'Accept-Language': 'en',
6     'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; WOW64) AppleWebKit/537.36 (KHTML, like
7     Gecko) Chrome/81.0.4044.122 Safari/537.36',
8 }
9 ITEM_PIPELINES = {
10     'Ppt.pipelines.PptPipeline': 300,
11 }
12 FILES_STORE = '/home/tarena/ppt/'

```

## scrapy - post请求

#### ■ 方法+参数

```
1 scrapy.FormRequest(  
2     url=posturl,  
3     formdata=formdata,  
4     callback=self.parse  
5 )
```

## 抓取全国所有城市肯德基门店信息

### 目标说明

```
1 【1】 主页URL地址  
2     http://www.kfc.com.cn/kfccda/storelist/index.aspx  
3  
4 【2】 抓取所有城市的肯德基门店信息  
5     2.1) 门店编号  
6     2.2) 门店名称  
7     2.3) 门店地址  
8     2.4) 所属城市  
9  
10 【3】 将所抓数据存储到MySQL数据库中  
11 <a href=".*?rel="(.*?)">
```

### 步骤1 - 创建项目+爬虫文件

```
1 scrapy startproject Kfc  
2 cd Kfc  
3 scrapy genspider kfc www.kfc.com.cn
```

### 步骤2 - 定义要抓取的数据结构(items.py)

```
1 import scrapy  
2  
3 class KfcItem(scrapy.Item):  
4     # 门店编号 + 门店名称 + 门店地址 + 所属城市  
5     row_num = scrapy.Field()  
6     store_name = scrapy.Field()  
7     address_detail = scrapy.Field()  
8     city_name = scrapy.Field()
```

### 步骤3 - 写爬虫程序(kfc.py)

```
1 # -*- coding: utf-8 -*-  
2 import scrapy  
3 import requests  
4 import json  
5 import re  
6 from ..items import KfcItem  
7  
8  
9 class KfcSpider(scrapy.Spider):
```

```

10     name = 'kfc'
11     allowed_domains = ['www.kfc.com.cn']
12     index_url = 'http://www.kfc.com.cn/kfccda/storelist/index.aspx'
13     post_url = 'http://www.kfc.com.cn/kfccda/ashx/GetStoreList.ashx?op=cname'
14     headers = {'User-Agent': 'Mozilla/5.0'}
15
16     # 经过分析为POST请求,故使用start_requests()方法
17     def start_requests(self):
18         """拼接多页地址,进行数据抓取"""
19         # 获取所有的城市
20         all_city = self.get_all_city()
21         for city in all_city:
22             # 获取每个城市的门店页数
23             total = self.get_total_page(city)
24             for i in range(1,total+1):
25                 # 此为抓包抓到的Form表单数据
26                 formdata = {
27                     "cname": city,
28                     "pid": "",
29                     "pageIndex": str(i),
30                     "pageSize": "10"
31                 }
32                 yield
33                 scrapy.FormRequest(url=self.post_url, formdata=formdata, callback=self.parse)
34
35     def get_all_city(self):
36         """获取所有的城市列表"""
37         html = requests.get(url=self.index_url, headers=self.headers).text
38         pattern = re.compile('<a href=".*?rel="(.*?)">', re.S)
39         all_city = pattern.findall(html)
40
41         return all_city
42
43     def get_total_page(self, city):
44         """获取某个城市的肯德基总数 - 向第1页发请求即可获得"""
45         data = {
46             "cname": city,
47             "pid": "",
48             "pageIndex": "1",
49             "pageSize": "10"
50         }
51         html = requests.post(url=self.post_url, data=data, headers=self.headers).json()
52         kfc_count = html['Table'][0]['rowcount']
53         total = kfc_count//10 if kfc_count%10==0 else kfc_count//10 + 1
54
55         return total
56
57     def parse(self, response):
58         html = json.loads(response.text)
59         kfc_shop_list = html['Table1']
60         for kfc_shop in kfc_shop_list:
61             item = KfcItem()
62             item['row_num'] = kfc_shop['rownum']
63             item['store_name'] = kfc_shop['storeName']
64             item['address_detail'] = kfc_shop['addressDetail']
65             item['city_name'] = kfc_shop['cityName']

```

#### ■ 步骤4 - 管道文件实现(pipelines.py)

```
1  # 存入MySQL管道
2  """
3  create database kfcdb charset utf8;
4  use kfcdb;
5  create table kfctab(
6  row_num int,
7  store_name varchar(100),
8  address_detail varchar(200),
9  city_name varchar(100)
10 )charset=utf8;
11 """
12 import pymysql
13 from .settings import *
14
15 class KfcMysqlPipeline(object):
16     def open_spider(self, spider):
17         self.db = pymysql.connect(MYSQL_HOST, MYSQL_USER, MYSQL_PWD, MYSQL_DB, charset=CHARSET)
18         self.cursor = self.db.cursor()
19         self.ins = 'insert into kfctab values(%s,%s,%s,%s)'
20
21     def process_item(self, item, spider):
22         shop_li = [
23             item['row_num'],
24             item['store_name'],
25             item['address_detail'],
26             item['city_name']
27         ]
28         self.cursor.execute(self.ins, shop_li)
29         self.db.commit()
30
31         return item
32
33     def close_spider(self, spider):
34         self.cursor.close()
35         self.db.close()
```

#### ■ 步骤5 - 全局配置(settings.py)

```
1  【1】ROBOTSTXT_OBEY = False
2  【2】DOWNLOAD_DELAY = 0.1
3  【3】DEFAULT_REQUEST_HEADERS = {
4      'Accept': 'text/html,application/xhtml+xml,application/xml;q=0.9,*/*;q=0.8',
5      'Accept-Language': 'en',
6      'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; WOW64) AppleWebKit/537.36 (KHTML, like
7      Gecko) Chrome/80.0.3987.149 Safari/537.36',
8  }
9  【4】ITEM_PIPELINES = {
10     'Kfc.pipelines.KfcMysqlPipeline': 300,
11 }
12 【5】MYSQL_HOST = 'localhost'
13 【6】MYSQL_USER = 'root'
```

```
13 【7】 MYSQL_PWD = '123456'
14 【8】 MYSQL_DB = 'kfcdb'
15 【9】 CHARSET = 'utf8'
```

#### ■ 步骤6 - 运行爬虫(run.py)

```
1 from scrapy import cmdline
2
3 cmdline.execute('scrapy crawl kfc'.split())
```

#### ■ 练习

```
1 请使用scrapy框架实现有道翻译案例
```

## 有道翻译案例实现

#### ■ 步骤1 - 创建项目+爬虫文件

```
1 scrapy startproject Youdao
2 cd Youdao
3 scrapy genspider youdao fanyi.youdao.com
```

#### ■ 步骤2 - items.py

```
1 result = scrapy.Field()
```

#### ■ 步骤3 - youdao.py

```
1 # -*- coding: utf-8 -*-
2 import scrapy
3 import time
4 import random
5 from hashlib import md5
6 import json
7 from ..items import YoudaoItem
8
9 class YoudaoSpider(scrapy.Spider):
10     name = 'youdao'
11     allowed_domains = ['fanyi.youdao.com']
12     word = input('请输入要翻译的单词:')
13
14     def start_requests(self):
15         post_url = 'http://fanyi.youdao.com/translate_o?smartresult=dict&smartresult=rule'
16         salt, sign, ts = self.get_salt_sign_ts(self.word)
17         formdata = {
18             'i': self.word,
19             'from': 'AUTO',
20             'to': 'AUTO',
21             'smartresult': 'dict',
```

```

22         'client': 'fanyideskweb',
23         'salt': salt,
24         'sign': sign,
25         'ts': ts,
26         'bv': 'cf156b581152bd0b259b90070b1120e6',
27         'doctype': 'json',
28         'version': '2.1',
29         'keyfrom': 'fanyi.web',
30         'action': 'FY_BY_REALTIME'
31     }
32     # 发送post请求的方法
33     yield scrapy.FormRequest(url=post_url, formdata=formdata)
34
35     def get_salt_sign_ts(self, word):
36         # salt
37         salt = str(int(time.time() * 1000)) + str(random.randint(0, 9))
38         # sign
39         string = "fanyideskweb" + word + salt + "n%A-rKaT5fb[Gy?;N5@Tj"
40         s = md5()
41         s.update(string.encode())
42         sign = s.hexdigest()
43         # ts
44         ts = str(int(time.time() * 1000))
45         return salt, sign, ts
46
47     def parse(self, response):
48         item = YoudaoItem()
49         html = json.loads(response.text)
50         item['result'] = html['translateResult'][0][0]['tgt']
51
52         yield item

```

#### ■ 步骤4 - pipelines.py

```

1 class YoudaoPipeline(object):
2     def process_item(self, item, spider):
3         print('翻译结果:', item['result'])
4         return item

```

#### ■ 步骤5 - settings.py

```

1  ROBOTSTXT_OBEY = False
2  LOG_LEVEL = 'WARNING'
3  COOKIES_ENABLED = False
4  DEFAULT_REQUEST_HEADERS = {
5      "Cookie": "OUTFOX_SEARCH_USER_ID=970246104@10.169.0.83;
OUTFOX_SEARCH_USER_ID_NCOO=570559528.1224236;
_ntes_nnid=96bc13a2f5ce64962adfd6a278467214,1551873108952;
JSESSIONID=aaae9i7p1XP1KaJH_gkYw; td_cookie=18446744072941336803;
SESSION_FROM_COOKIE=unknown; __rl__test__cookies=1565689460872",
6      "Referer": "http://fanyi.youdao.com/",
7      "User-Agent": "Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML,
like Gecko) Chrome/76.0.3809.100 Safari/537.36",
8  }
9  ITEM_PIPELINES = {
10     'Youdao.pipelines.YoudaoPipeline': 300,
11 }

```

#### ■ 步骤6 - run.py

```

1  from scrapy import cmdline
2
3  cmdline.execute('scrapy crawl youdao'.split())

```

## scrapy添加cookie的三种方式

```

1  【1】修改 settings.py 文件
2      1.1) COOKIES_ENABLED = False -> 取消注释,开启cookie,检查headers中的cookie
3      1.2) DEFAULT_REQUEST_HEADERS = {} 添加Cookie
4
5  【2】利用cookies参数
6      1.1) settings.py: COOKIES_ENABLED = True # 修改为TRUE后, 检查 Request()方法中cookies
7      1.2) def start_requests(self):
8              yield scrapy.Request(url=url,cookies={},callback=xxx)
9              yield scrapy.FormRequest(url=url,formdata=formdata,cookies={},callback=xxx)
10
11 【3】DownloadMiddleware设置中间件
12      3.1) settings.py: COOKIES_ENABLED = TRUE # 找Request()方法中cookies参数
13      3.2) middlewares.py
14              def process_request(self,request,spider):
15                  request.cookies={}
16
17 【铭记三句话】
18      1. scrapy默认禁用Cookie : 在什么地方加cookie都没用
19      2. False : 找 DEFAULT_REQUEST_HEADERS={'Cookie':''} 中的Cookie
20      3. True : 找爬虫文件中 yield scrapy.Request(url=url,callback=xxx,cookies={}) 中cookies参数

```

## scrapy shell的使用

## ▪ 定义

- ```
1 【1】 调试蜘蛛的工具
2 【2】 交互式shell, 可在不运行spider的前提下,快速调试 scrapy 代码(主要测试xpath表达式)
```

## ▪ 基本使用

```
1 # scrapy shell URL地址
2 *1、 request.url      : 请求URL地址
3 *2、 request.headers  : 请求头(字典)
4 *3、 request.meta     : item数据传递, 定义代理(字典)
5 *4、 request.cookies  : Cookie (字典)
6
7 4、 response.text     : 字符串
8 5、 response.body     : bytes
9 6、 response.xpath('')
10 7、 response.status  : HTTP响应码
11 8、 response.url
12
13 # 可用方法
14 shelp() : 帮助
15 fetch(request) : 从给定的请求中获取新的响应, 并更新所有相关对象
16 view(response) : 在本地Web浏览器中打开给定的响应以进行检查
```

## ▪ scrapy.Request()参数

```
1 1、 url
2 2、 callback
3 3、 headers
4 4、 meta : 传递数据,定义代理
5 5、 dont_filter : 是否忽略域组限制
6 默认False,检查allowed_domains['']
7 6、 cookies
```

# 设置中间件(随机User-Agent)

## ▪ 少量User-Agent切换

```
1 【1】 方法一 : settings.py
2 1.1) USER_AGENT = ''
3 1.2) DEFAULT_REQUEST_HEADERS = {}
4
5 【2】 方法二 : 爬虫文件
6 yield scrapy.Request(url,callback=函数名,headers={})
```

## ▪ 大量User-Agent切换 (middlewares.py设置中间件)

```
1 【1】 获取User-Agent方式
2 1.1) 方法1 : 新建useragents.py,存放大量User-Agent, random模块随机切换
3 1.2) 方法2 : 安装fake_useragent模块(sudo pip3 install fake_useragent)
4 from fake_useragent import UserAgent
```



```

5         agent = UserAgent().random
6
7     【2】middlewares.py新建中间件类
8     class RandomUseragentMiddleware(object):
9         def process_request(self, request, spider):
10             agent = UserAgent().random
11             request.headers['User-Agent'] = agent
12
13     【3】settings.py添加此下载器中间件
14     DOWNLOADER_MIDDLEWARES = {'': 优先级}

```

## 设置中间件(随机代理)

```

1 class RandomProxyDownloaderMiddleware(object):
2     def process_request(self, request, spider):
3         request.meta['proxy'] = xxx
4
5     def process_exception(self, request, exception, spider):
6         return request

```

### ■ 练习

1 有道翻译,将cookie以中间件的方式添加的scrapy项目中

## 今日作业

```

1     【1】URL地址
2         1.1) www.so.com -> 图片 -> 美女
3         1.2) 即: https://image.so.com/z?ch=beauty
4         1.3) 抓取5页即可, 共计150张图片
5
6     【2】图片保存路径
7         /home/tarena/images/xxx.jpg
8         /home/tarena/images/青涩美女.jpg
9
10    【提示】: 使用 from scrapy.pipelines.images import ImagesPipeline 管道,并重写方法
11
12    settings.py: IMAGES_STORE = '路径'
13
14    作业2: scrapy实现有道翻译
15        【1】post请求
16        【2】输入翻译内容: 直接打印输出翻译结果,不需要显示日志
17        【3】Scrapy中Cookie的使用 (用3种方式实现)

```

# 答案

## ■ 抓取网络数据包

```
1  【1】通过分析, 该网站为Ajax动态加载
2  【2】F12抓包, 抓取到json地址 和 查询参数(QueryString)
3      2.1) url = 'https://image.so.com/zjl?ch=beauty&sn={}&listtype=new&temp=1'
4      2.2) 查询参数
5              ch: beauty
6              sn: 0 # 发现sn的值在变, 0 30 60 90 120 ... ...
7              listtype: new
8              temp: 1
```

## 项目实现

### ■ 1、创建爬虫项目和爬虫文件

```
1 scrapy startproject So
2 cd So
3 scrapy genspider so image.so.com
```

### ■ 2、定义要爬取的数据结构(items.py)

```
1 img_url = scrapy.Field()
2 img_title = scrapy.Field()
```

### ■ 3、爬虫文件实现图片链接+名字抓取

```
1 import scrapy
2 import json
3 from ..items import SoItem
4
5 class SoSpider(scrapy.Spider):
6     name = 'so'
7     allowed_domains = ['image.so.com']
8     # 重写start_requests()方法
9     url = 'https://image.so.com/zjl?ch=beauty&sn={}&listtype=new&temp=1'
10
11     def start_requests(self):
12         for sn in range(0, 91, 30):
13             full_url = self.url.format(sn)
14             # 扔给调度器入队列
15             yield scrapy.Request(url=full_url, callback=self.parse_image)
16
17     def parse_image(self, response):
18         html = json.loads(response.text)
19         item = SoItem()
20         for img_dict in html['list']:
21             item['img_url'] = img_dict['qhimg_url']
22             item['img_title'] = img_dict['title']
```

```
23  
24         yield item
```

#### ■ 4、管道文件 (pipelines.py)

```
1  from scrapy.pipelines.images import ImagesPipeline  
2  import scrapy  
3  
4  class SoPipeline(ImagesPipeline):  
5      # 重写get_media_requests()方法  
6      def get_media_requests(self, item, info):  
7          yield scrapy.Request(url=item['img_url'], meta={'name': item['img_title']})  
8  
9      # 重写file_path()方法, 自定义文件名  
10     def file_path(self, request, response=None, info=None):  
11         img_link = request.url  
12         # request.meta属性  
13         filename = request.meta['name'] + '.' + img_link.split('.')[ -1]  
14         return filename
```

#### ■ 5、全局配置(settings.py)

```
1  ROBOTSTXT_OBEY = False  
2  DOWNLOAD_DELAY = 0.1  
3  DEFAULT_REQUEST_HEADERS = {  
4      'Accept': 'text/html,application/xhtml+xml,application/xml;q=0.9,*/*;q=0.8',  
5      'Accept-Language': 'en',  
6      'User-Agent': 'Mozilla/5.0',  
7  }  
8  ITEM_PIPELINES = {  
9      'So.pipelines.SoPipeline': 300,  
10 }  
11 IMAGES_STORE = './images/'
```

#### ■ 6、运行爬虫(run.py)

```
1  from scrapy import cmdline  
2  
3  cmdline.execute('scrapy crawl so'.split())
```